



PRÁCTICA 1

SOFT COMPUTING

IMPLEMENTACIÓN DE ESTRATEGIAS EVOLUTIVAS BÁSICAS Y ALGORITMOS
EVOLUTIVOS BINARIOS



28 DE DICIEMBRE DE 2020

CARMEN MARTÍNEZ ESTÉVEZ - 09070605A - ALBERTO MARTÍNEZ ORTEGA - 04638602P

EJERCICIO 1.1 – Estrategia evolutiva (1+1)-ES

Estrategia evolutiva que considera un único individuo, y que muta un hijo a partir de ruido gaussiano.

La función principal es *'unomasuno'*, a la que le pasamos por parámetro una sigma que es la varianza del ruido Gaussiano. Esta función nos devuelve el individuo y su fitness.

Lo primero es generar el individuo, que será un vector de una fila y 30 columnas, de números aleatorios que van de -100 a 100. A continuación, calculamos su fitness llamando a la función *'funcion_optim'* a la que le pasamos el individuo generado.

Ahora entramos en un bucle for de 300000 iteraciones, en el que vamos a generar un hijo del individuo, con valores creados a partir del valor del individuo y aplicándole el valor sigma.

Una vez generado el hijo, comprobamos que ningún valor de los 30 que componen el hijo excede de los límites [-100,100]. Si algún valor es más pequeño que -100, lo actualizamos a -100, y si algún valor supera 100, se actualiza a 100.

Tras la comprobación calculamos el fitness del hijo, llamando nuevamente a *'funcion_optim'*, pasándole el hijo.

Por último, comprobamos si el hijo generado tiene un fitness mejor que el del individuo, en cuyo caso actualizamos el valor de individuo sustituyéndole por el hijo, y también actualizamos el valor fitness.

Y así en cada iteración del bucle.

```
function [individuo, individuo_fit, grafica_fitness] = unomasuno(sigma)

individuo = -100+(100+100)*rand(1, 30)
individuo_fit = funcion_optim(individuo)
grafica_fitness=zeros(1, 300001);
grafica_fitness(1)=individuo_fit;
for i = 1:300000
    hijo=individuo+(randn(1,30)*sigma);

    for j=1:30
        if hijo(j)>100
            hijo(j)=100;
        elseif hijo(j)<(-100)
            hijo(j)=-100;
        end
    end

    hijo_fit=funcion_optim(hijo);

    if hijo_fit < individuo_fit
        individuo_fit = hijo_fit;
        individuo = hijo;
    end
    grafica_fitness(i+1)=individuo_fit;
end
```

A la funcion_optim le pasamos un individuo, y nos calcula su fitness. Con un bucle for nos recorre el vector del individuo, y va sumando cada valor del vector al cuadrado.

```
function individuo_fit = funcion_optim(individuo)

individuo_fit=0;

for i=1:length(individuo)
    individuo_fit=individuo_fit+(individuo(i)^2);
end
```

El main es el siguiente:

```
clc;
clear all;
close all;

[individuo, fitness1, grafical]=unomasuno(0.01);
disp("Individuo");
disp(individuo);
disp("Fitness");
disp(fitness1);
axis on;
hold on;
title("UNOMASUNO");
xlabel("N° de iteraciones");
ylabel("Fitness");
plot(grafical);
hold off;
```

El resultado obtenido de ejecutarlo es el siguiente:

Individuo padre y su fitness:

```
individuo =
Columns 1 through 15
    28.5306    48.5773    29.9126    91.4320    52.6178   -78.9626   -94.0684   -36.4126   -60.0983    91.5944   -67.7954   -59.4303   -6.9713   -0.7896   -86.2944
Columns 16 through 30
   -23.5014   -72.1797     4.3729    58.2768    49.6282    54.6515    36.2285     3.5907    72.8966    61.3576     7.5992   -71.8352   -59.3034    77.0531    47.9678

individuo_fit =
    1.0124e+05
```

El hijo con mejor fitness y su fitness:

```
Individuo
Columns 1 through 15
   -0.0036     0.0034     0.0005   -0.0033     0.0014   -0.0018     0.0031     0.0038     0.0006   -0.0057     0.0120     0.0019   -0.0007     0.0001     0.0044
Columns 16 through 30
   -0.0085   -0.0033   -0.0092     0.0015   -0.0108   -0.0005     0.0086     0.0001     0.0128     0.0033   -0.0018     0.0115     0.0146   -0.0025     0.0019

Fitness
    0.0012
```

EJERCICIO 1.2 – Estrategia evolutiva ($\lambda + \mu$)-ES

En este caso hay λ padres y forman μ hijos cada uno. El procedimiento es el mismo que en el apartado anterior solo que considerando cada uno de los individuos con sus hijos.

Cogemos cada uno de los 10 padres y, mutándolos con ruido Gaussiano, obtenemos 5 hijos para cada uno. Después comparamos el fitness de cada uno de los hijos y escogemos el mejor.

Posteriormente comparamos el fitness del mejor hijo con el de su padre y, en caso de ser mejor, actualizamos la población sustituyendo al padre por dicho hijo, así como el conjunto de fitness de la población, donde introducimos el nuevo fitness del individuo.

Las funciones desarrolladas para esto son las siguientes:

La función `lambdamasmu` realiza el grueso de las operaciones, con un total de 100000 iteraciones. Le pasamos los parámetros `sigma` (definimos el ruido), `tam_pob`, `lambda` y `mu`. Estos 3 últimos definen el tamaño de cada individuo, el número de padres y de hijos respectivamente. También nos encontramos dentro del `lambdamasmu.m` otra función llamada `'hijos_dev'` que actualiza los valores de los hijos en caso de que estos estén fuera de los límites de `[-100, 100]`.

```
function [poblacion, poblacion_fit, grafica_fitness] = lambdamasmu(sigma, tam_pob, lambda, mu)

poblacion = -100+(100+100)*randn(lambda, tam_pob)

poblacion_fit=zeros(1,lambda);
grafica_fitness=zeros(100001, lambda);

for i=1:lambda
    poblacion_fit(i) = funcion_optim(poblacion(i,:))
end

grafica_fitness(1,:)=poblacion_fit;

for j = 1:100000

    for k=1:lambda
        hijos=zeros(mu, tam_pob);
        hijos_fitness=zeros(1,mu);
        for l=1:mu
            hijos(l,:)=(poblacion(k,:)+(randn(1, tam_pob)*sigma));
        end

        hijos=comprobar_hijos(hijos, tam_pob, mu);

        for m=1:mu
            hijos_fitness(m)=funcion_optim(hijos(m,:));
            if hijos_fitness(m)<poblacion_fit(k)
                poblacion(k,:)=hijos(m,:);
                poblacion_fit(k)=hijos_fitness(m);
            end
        end

    end

    grafica_fitness(j+1,:)=poblacion_fit;
end
end
```

```

function hijos_dev = comprobar_hijos(hijos, tam_pob, mu)
hijos_dev=zeros(mu, tam_pob);
    for i=1:mu
        for j=1:tam_pob
            if hijos(i,j)<-100
                hijos_dev(i,j)=-100;
            elseif hijos(i,j)>100
                hijos_dev(i,j)=100;
            else
                hijos_dev(i,j)=hijos(i,j);
            end
        end
    end
end
end

```

La función main, limpia la consola, cierra posibles ventanas abiertas y borra todas las variables previas del Workspace. Después llama a la función 'lambdamasmu' con los parámetros sigma=0.01, tam_pob=30, lambda=10, mu=5. Una vez terminada la ejecución recoge en las variables 'poblacion', 'fitness2' y 'grafica2' el resultado final obtenido que es mostrado por consola en el caso de las dos primeras y con un plot gráfico para observar la evolución del algoritmo.

```

clc;
clear all;
close all;
[poblacion, fitness2, grafica2]=lambdamasmu(0.01,30,10,5);
disp("Poblacion");
disp(poblacion);
disp("Fitness");
disp(fitness2);
axis on;
hold on;
title("LAMB DAMAS MU");
xlabel("N° de iteraciones");
ylabel("Fitness");
plot(grafica2);
hold off;

```

Por último, comentar que la función optimizadora es la misma que en el caso anterior. Se trata de minimizar a 0 los datos de cada individuo. La única diferencia es que, en este caso, la función ha de recorrer un array bidimensional, para lo cual se han usado 2 bucles anidados a diferencia del bucle único del caso anterior.

```

function [hijo_fit]=funcion_optim2(hijos)

hijo_fit=0;
for i = 1:10
    for j=1:30
        for k=1:5
            hijo_fit=(sum(hijos(i,j,k))^2);
        end
    end
end
end

```

Tras ejecutar el main obtenemos lo siguiente:

Una muestra de los 10 padres y el fitness de cada uno

```
Columns 1 through 14

7.5334 -369.9774 34.2994 77.6791 -120.4485 -272.7306 -317.8129 -223.1204 183.8620 -329.5906 68.0751 -527.6711 481.6016 -170.7700
266.7770 506.9847 -341.4974 -329.4140 -148.2894 -84.5282 -93.4885 49.6154 -41.6831 -79.0251 -277.6064 -267.9177 65.0438 -264.7173
-551.7694 45.0808 43.4477 -313.7741 -36.1587 -342.8234 10.5054 -138.4837 -60.4378 44.4508 -79.9814 170.9189 175.7944 -415.4114
72.4347 -112.6110 226.0471 -261.8997 -37.4283 -322.7001 120.1220 77.7221 217.5398 417.0983 -208.9058 -314.4311 -311.6361 1.5949
-36.2470 42.9486 -2.2212 -688.8568 -272.9760 -101.3699 208.8424 -252.9698 -260.8932 -233.3781 -39.2958 92.1908 -193.7231 -43.6032
-361.5377 -140.9932 106.9386 187.6761 -106.0103 206.5261 -82.8138 -380.4538 39.3249 -62.5338 -220.0653 -75.1900 -154.4939 -93.3040
-186.7184 -124.8289 45.3770 -34.9619 -132.9758 -253.9332 -398.3181 -384.4752 67.0176 -116.4989 -2.0069 187.3393 119.6849 -366.7356
-31.4751 197.9395 -160.6882 -250.9857 25.5415 -25.7242 -248.4604 -2.3612 -148.7430 -486.6046 47.8726 -492.1800 -155.5744 125.4985
615.6794 181.8069 -41.2257 174.0597 118.6531 -145.1169 -312.3163 -135.4750 -56.8660 -187.7932 242.3776 -139.5396 40.3083 -29.9641
453.8874 183.4385 -257.4566 -442.3033 121.8547 123.4712 370.0914 -139.2107 -333.1688 -458.9358 -138.8247 -341.5691 -510.3633 -159.8132

Columns 15 through 28

-95.4220 4.0120 -158.7507 -366.4009 -372.3389 -139.0442 -63.3545 -206.4023 -312.8427 -21.6212 -313.3403 -246.8338 100.0122 -34.5880
-152.3991 -104.0056 -269.5852 -565.9734 -8.9941 -143.5213 -305.9535 236.4207 220.6915 -350.1358 86.7456 -106.1627 -432.8329 116.5267
-450.0425 -106.9542 -324.0257 -389.8195 -269.7419 -160.6215 89.8444 -275.1459 146.9358 -289.5922 -29.9358 -53.5306 -218.0069 101.2154
-157.1302 -259.6327 405.1999 -33.2978 -166.9774 -95.3909 -38.5876 -196.7630 -145.9253 -248.2212 -105.8012 -14.7225 -155.6128 -230.1815
-266.2733 103.7371 231.0995 -21.7293 10.5567 -89.7419 -72.9650 -242.4009 -401.2319 -201.5635 -63.5096 -174.5617 -15.4569 -48.5888
-295.8413 -126.6435 -38.4930 -9.6641 107.8181 65.2126 3.0493 -334.8425 -189.9256 -164.1151 -413.0112 -147.2909 -434.0401 -288.8756
-331.2803 -242.9060 -351.4237 -126.0569 -323.5277 205.3953 -47.7187 -138.4479 -131.1882 -97.5062 -116.9079 304.7382 -5.6731 -364.3577
-206.7114 170.2772 -273.0936 -63.2622 152.1317 -6.6171 -288.2972 -154.8140 -44.7863 -705.8355 220.7893 -551.6708 -342.5694 84.9652
-500.5271 -144.9542 -135.3068 -195.2306 32.0286 -141.9427 -132.4675 206.0145 -152.2327 -191.4029 -80.3304 345.8891 -86.7620 -99.9900
92.8459 -217.8058 58.2832 72.4043 -113.5731 25.0381 -129.2109 -149.8049 -11.3156 148.4897 -91.7253 -32.4873 30.4712 -110.9838

poblacion_fit =

1.0e+06 *

1.7300 2.0533 1.6216 1.2584 1.3059 1.2705 1.8002 2.0472 1.6361 2.0902
```

Tras superar las 100.000 iteraciones el resultado es el siguiente:

```
Columns 1 through 14

0.0058 0.0020 -0.0001 -0.0054 -0.0020 -0.0039 -0.0067 0.0042 0.0054 -0.0100 0.0004 -0.0068 0.0025 0.0010
-0.0030 -0.0054 0.0051 -0.0014 0.0070 0.0080 0.0113 0.0031 -0.0081 0.0037 -0.0033 0.0104 0.0001 -0.0026
0.0081 -0.0029 0.0045 0.0019 0.0047 0.0016 0.0096 -0.0010 -0.0025 -0.0052 -0.0010 0.0028 -0.0054 0.0037
-0.0113 0.0067 0.0092 -0.0040 0.0021 0.0060 -0.0078 -0.0096 -0.0080 -0.0038 0.0015 0.0016 -0.0048 -0.0008
-0.0040 -0.0006 0.0013 0.0050 0.0071 0.0061 0.0114 0.0149 0.0057 0.0057 0.0022 0.0003 -0.0047 0.0002
0.0146 -0.0068 -0.0067 0.0022 0.0096 0.0050 -0.0030 -0.0058 0.0041 -0.0020 0.0045 0.0019 -0.0021 -0.0009
0.0028 0.0019 0.0062 -0.0016 0.0094 -0.0079 0.0001 -0.0015 -0.0017 -0.0060 -0.0003 0.0067 -0.0086 0.0001
0.0016 0.0011 0.0027 -0.0068 -0.0083 -0.0003 -0.0047 0.0021 0.0035 0.0032 -0.0039 0.0035 0.0009 -0.0019
-0.0052 -0.0079 0.0051 -0.0060 -0.0070 0.0007 -0.0051 0.0098 0.0050 0.0073 -0.0045 -0.0013 0.0072 -0.0005
0.0050 0.0089 0.0002 -0.0095 -0.0022 -0.0038 -0.0056 0.0013 -0.0025 -0.0065 0.0029 0.0057 0.0025 0.0036

Columns 15 through 28

-0.0096 0.0001 -0.0051 0.0190 -0.0033 -0.0058 0.0008 0.0088 -0.0068 -0.0037 -0.0039 -0.0007 -0.0001 -0.0018
-0.0016 -0.0010 -0.0016 -0.0020 -0.0036 -0.0017 0.0015 -0.0024 -0.0008 -0.0057 0.0044 0.0022 0.0052 0.0047
0.0008 0.0176 0.0101 -0.0033 -0.0022 0.0029 0.0011 0.0024 -0.0070 0.0060 -0.0056 -0.0052 0.0147 0.0038
0.0040 -0.0046 0.0121 0.0019 -0.0009 -0.0047 0.0001 -0.0086 -0.0021 -0.0028 0.0125 0.0033 0.0041 -0.0017
0.0094 -0.0113 0.0056 0.0007 -0.0062 0.0072 -0.0053 -0.0060 -0.0028 0.0005 -0.0045 -0.0007 -0.0006 -0.0015
0.0021 0.0029 0.0048 0.0101 0.0011 0.0034 0.0007 0.0040 0.0103 -0.0029 0.0082 -0.0025 -0.0018 0.0026
0.0150 0.0045 -0.0062 0.0053 -0.0089 0.0041 -0.0007 0.0010 -0.0023 0.0029 -0.0019 -0.0079 0.0001 -0.0096
-0.0013 -0.0100 0.0039 -0.0007 0.0079 0.0079 -0.0015 -0.0144 -0.0055 -0.0079 -0.0007 -0.0023 0.0003 0.0005
0.0096 0.0027 0.0023 -0.0033 -0.0016 0.0015 -0.0012 -0.0020 0.0141 -0.0078 0.0031 -0.0048 0.0090 -0.0067
-0.0091 0.0031 0.0037 0.0000 -0.0093 -0.0011 -0.0073 -0.0052 -0.0024 -0.0030 -0.0000 0.0046 -0.0034 0.0036

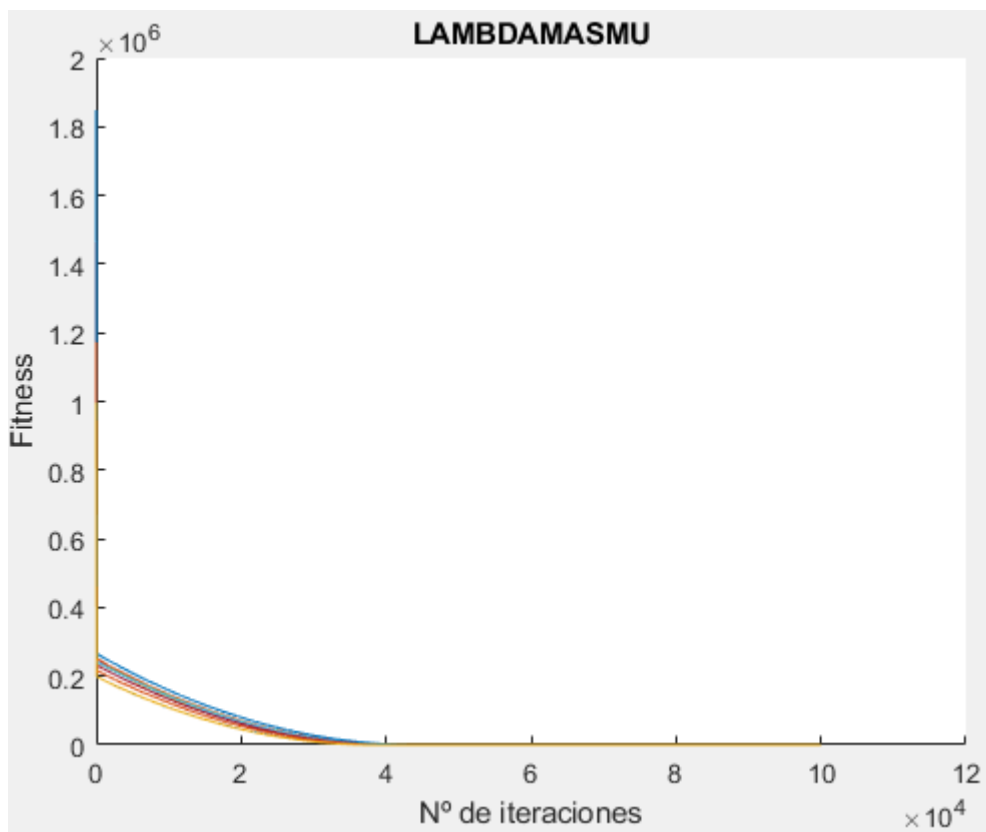
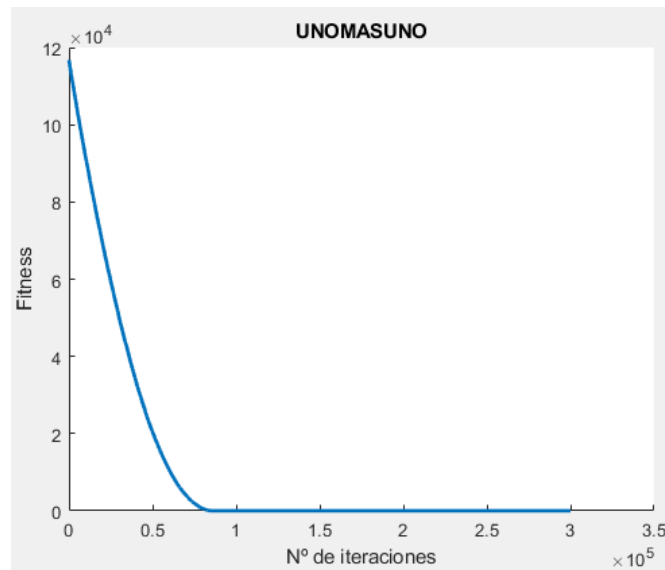
Fitness

0.0011 0.0009 0.0011 0.0011 0.0010 0.0009 0.0009 0.0009 0.0011 0.0007
```

Por último, nos gustaría comentar los resultados, así como los parámetros elegidos para la simulación de estos algoritmos.

Comenzamos por los parámetros haciendo especial mención al parámetro sigma. Comenzamos probando con una sigma de valor 10 y los resultados obtenidos eran totalmente aleatorios. Conforme fuimos bajando el parámetro, íbamos obteniendo valores mucho más ajustados a lo que se nos pedía. Bajamos tanto el valor de sigma, a 0.0001, que el algoritmo no se ejecutaba correctamente. Entonces comprendimos que bajando tanto la sigma, los padres apenas mutaban para ‘dar a luz’ a sus hijos y, por ello, por muchas iteraciones que realizásemos, el resultado nunca iba a converger a 0.

Hay que destacar también que, tal y como podemos observar en el código, hemos ido guardando el fitness de cada una de las iteraciones en una variable para luego poder visualizarlos en forma de gráfica. Estos son los resultados obtenidos:



Tal y como cabía esperar, al principio el fitness cae en picado por la rápida mutación de los individuos. Como en el lambdamasmu tenemos 5 hijos para elegir, es lógico que este descienda aún más rápido que en el unomasuno. Después, conforme nos acercamos a 0, se ralentiza la bajada hasta llegar a valores de $\times 10^{-3}$ aproximadamente en ambos casos. La diferencia al principio entre individuos en el segundo caso es ínfima y depende de la generación aleatoria inicial.

EJERCICIO 2 – Algoritmo genético básico con codificación binaria.

Vamos a proceder a la programación de un algoritmo genético siguiendo el esquema ($\lambda + \mu$), es decir, lambda padres que generan un hijo cada uno. Esto lo hacemos utilizando 3 operadores.

Primero cruzamos a los padres para generar a los hijos. El esquema seguido ha sido el siguiente: en cada iteración se escoge un punto de cruce distinto, del 1 al 1000. Con esta división hecha, el hijo 1 estará formado por los elementos del padre 1 hasta dicho punto de corte más los elementos del padre 2 que estén a partir del punto de corte. El hijo 2 será formado por los padres 2 y 3 y así sucesivamente. Cuando lleguemos al hijo 1000, cogeremos los x primeros dígitos del padre 1000 y los x segundos del padre 1 para completar el círculo.

Una vez obtenidos los hijos mediante el cruce procedemos a mutarlos para otorgarles algo más de diversidad genética. Cada hijo tiene una probabilidad de mutar del 3%, y en caso de que mute, lo hace un 20% del total de sus dígitos (200 de 1000). Esto se ha decidido así tras escuchar las consideraciones hechas en clase al respecto por el profesor. Nos gustaría aclarar que generar números aleatorios es un mundo complejo y se ha estudiado la mejor forma de que estos sean realmente aleatorios, llegando a una solución que consideramos la mejor de las posibles.

La función 'binario' se encarga de generar la población inicial, calcular su fitness y entrar en las 5000 iteraciones con el procedimiento arriba descrito:

```
function [poblacion, fitness, grafica]=binario(n_iteraciones, n_individuos, longitud)

poblacion=zeros(n_individuos, longitud);
fitness=zeros(1, n_individuos);
grafica=zeros(n_iteraciones, n_individuos);
for i=1:n_individuos
    for j=1:longitud
        poblacion(i,j) = randi([0,1]);
    end
    fitness(i)=funcion_fit(poblacion(i,:));
end
grafica(1,:)=fitness;
poblacion
fitness

fitness_hijos=zeros(1, n_individuos);

for k=1:n_iteraciones
    hijos_cruce=crucepunto(poblacion);
    hijos_mutados=mutacion(hijos_cruce);
    for m=1:n_individuos
        fitness_hijos(m)=funcion_fit(hijos_mutados(m,:));
        if fitness_hijos(m)>fitness(m)
            poblacion(m,:)=hijos_mutados(m,:);
            fitness(m)=fitness_hijos(m);
        end
    end
    grafica(k+1,:)=fitness;
end
end
```


Tal y como sucedía en el apartado 1, se compara el fitness de cada hijo con su padre y, en caso de ser mejor, se actualiza la población y el valor fitness correspondiente.

Conforme se comentaba antes, aquí podemos observar el código de la función de cruce, que utiliza una mitad de un individuo y otra mitad del siguiente para generar cada hijo.

```
function hijos = crucepunto(padres)

hijos=zeros(100,1000);
puntodecruce=ceil(rand()*1000);

for i=1:100
    for j=1:puntodecruce
        hijos(i,j)=padres(i,j);
    end
    indice=puntodecruce+1;
    for k=indice:1000
        if i~=100
            indice2=i+1;
            hijos(i,k)=padres(indice2,k);
        else
            hijos(100,k)=padres(1,k);
        end
    end
end
end
```

En la función mutación se ha utilizado un generador de números aleatorios en función de la fecha actual para que cada ejecución genere una tupla de números aleatorios distintos. Así conseguimos que la elección de si el individuo muta, y en su caso, qué valores mutan, sea lo más aleatoria posible.

```
function hijos=mutacion(padres)

hijos=padres;
rng('shuffle');
for i=1:100

    random=rand();
    if random<0.02 %probabilidad de 2%. si muta, muta un 20% del individuo.
        valor_mutante= randi([1 1000],1,200);
        for j=1:200
            random2=rand();
            if random2<=0.5
                hijos(i, valor_mutante(j))=1;
            else
                hijos(i, valor_mutante(j))=0;
            end
        end
    end
end
end
end
```

Para el procedimiento de mutación se ha decidido hacer un 50/50 sobre si el valor muta a uno o a 0, independientemente del valor que tuviera. Puede sonar extraño, pero tras unas cuantas pruebas nos dimos cuenta de que, continuamente estábamos teniendo en cuenta el objetivo (maximizar el número de unos) y esta fue la solución más justa y alejada de partidismos que encontramos.

Nos queda comentar dos funciones muy sencillas como son la función optimizadora:

```
function unos = funcion_fit(vector)
unos=0;
for i=1:length(vector)
    if vector(i)==1
        unos=unos+1;
    end
end
end
```

Esta función tiene la sencilla misión de contar el número de unos de un vector y devolvernos dicho resultado. Después en la función binario, se mira a ver qué individuo tiene mayor número de unos para conseguir el objetivo de maximizar el número de unos de la población.

Por último, el main que ejecuta la función binario y que muestra los resultados finales:

```
clc;
clear all;
[poblacion, fitness, grafica]=binario(5000, 100, 1000);
disp("Poblacion");
disp(poblacion);
disp("Fitness");
disp(fitness);
hold on;
axis on;
title("Maximizar unos");
ylabel("Fitness");
xlabel("Iteraciones");
plot(grafica);
```

Si ejecutamos dicha función obtenemos los siguientes resultados:

```
fitness =

Columns 1 through 23
488 518 524 514 501 489 514 489 489 516 505 475 516 514 481 510 495 507 514 512 467 509 482

Columns 24 through 46
491 498 513 491 504 483 508 537 518 506 478 518 490 509 516 492 468 502 491 506 488 498 483

Columns 47 through 69
518 490 519 474 500 494 493 504 510 502 481 474 491 473 511 478 498 513 494 498 493 501 521

Columns 70 through 92
515 482 500 512 514 489 519 507 505 523 513 494 494 484 489 521 514 502 501 505 505 494 504

Columns 93 through 100
517 469 488 524 506 493 503 503
```

Estos son los valores fitness de la población inicial. Como podemos observar están alrededor de 500 (número de unos) pues la generación inicial se hace de manera aleatoria.

```
Fitness
Columns 1 through 23
762 762 762 761 761 761 761 761 761 761 761 761 761 760 761 761 762 762 761 761 760

Columns 24 through 46
761 761 761 760 759 759 759 759 760 761 760 760 760 761 762 762 761 761 763 762 762 762 762

Columns 47 through 69
762 762 762 762 762 762 762 762 761 760 760 759 762 762 762 762 762 762 763 762 762 762

Columns 70 through 92
763 763 763 763 763 762 763 763 762 762 761 761 760 761 761 761 762 762 761 760 761 761 761

Columns 93 through 100
762 762 762 762 762 762 761 762
```

Tras terminar la ejecución obtenemos un fitness comprendido entre 759 y 763.

Cabe destacar, como curiosidad, que en las primeras columnas de datos encontramos resultados de unos y ceros más intercalados. Conforme avanzamos en las columnas nos encontramos con filas enteras de unos o ceros. Se han omitido estos resultados en la memoria porque son 100*1000 unos o ceros que coparían las páginas de este documento sin ningún sentido.

Para finalizar podemos observar la evolución del fitness a lo largo de las ejecuciones gracias a la variable gráfica que va almacenando dicho valores iteración tras iteración. Se observa un gran lío debido a que estamos tratando con 100 individuos diferentes. No obstante, se puede observar correctamente la tendencia del fitness:

